

REPUBLIQUE DU SENEGAL



Université Alioune Diop

L'Excellence est ma constance, l'Éthique ma vertu !

UFR : Science Appliquée de Technologie de l'Informatique et de la Communication (SATIC)

Master en Statistique et Informatique Décisionnelle (SID)

Projet de Séries temporelles

Sujet : « Etude de la tendance d'une série temporelle (production électrique mensuelle de 1985 à 2018), ensuite prédire la production électrique pour les années à venir en utilisant les processus ARIMA et la méthode de lissage. »

Présenté par :

Amadou BA

Mahmoud SIDIBE

Année académique :

2022-2023

Encadreur :

Pr Aba DIOP

Table des matières

1) Décomposez la série et faites une description et un ajustement de la tendance en utilisant un modèle linéaire simple et multiple. Comparer les deux modèles.....	3
2) Faisons une étude de la saisonnalité et analysons les résultats.	13
3) Modéliser la série par la méthodologie de Box & Jenkins. Analyser et interpréter les sorties du logiciel R.....	14
4) Effectuer une prévision par ARIMA de la production électrique pour une période d'une année et une période de 3 années. Représenter graphiquement ces prévisions dans deux graphes différents avec leurs intervalles de confiance. Commenter.....	21
5) Effectuer une prévision pour une année et pour 3 années par lissage exponentiel et comparer graphiquement ces valeurs avec celles obtenues par la méthode ARIMA.	25
Lissage Exponentiel pour un an.....	25
Lissage Exponentiel pour trois ans.....	28
6) validation par apprentissage-test.....	32
Lissage exponentiel.....	37

Contexte:

On souhaite modéliser les données de la production électrique mensuelle de 1985 à 2018 d'un pays donné. L'objectif de cette étude consiste d'abord à étudier la tendance de la série, ensuite prédire la production électrique pour les années à venir en utilisant les processus ARIMA et la méthode de lissage.

Travail à faire

1) Décomposez la série et faites une description et un ajustement de la tendance en utilisant un modèle linéaire simple et multiple. Comparer les deux modèles.

Chargement des packages

Chargeons les packages nécessaires sans les afficher le code dans le document

```
library(forecast)
```

```
library(TSstudio)
```

```
library(tseries)
```

```
library(plotly)
```

```
library(tidyverse)
```

```
library(stats)
```

```
library(dplyr)
```

```
library(ggplot2)
```

```
library(dygraphs)
```

```
library(lubridate)
```

```
library(datasets)
```

```
library(base)
```

```
library(Quandl)
```

```
library(ggfortify)
```

```
library(urca)
```

```
library(zoo)
```

```
library(TSA)
```

```
library(readxl)
```

Importation de la base

```
#Importation de la base
```

```
mabase <- read_excel("C:/Users/sidibe/Documents/Downloads/Projet/Aba/Base-  
Production_Electrique.xlsx")
```

```
## Affichage des 10 premiers valeurs de la base
```

```
mabase_head <- head(mabase, 10)  
mabase_head
```

```
# A tibble: 10 × 2
```

	DATE	PRODUCTION
	<dtm>	<chr>
1	1985-01-01 00:00:00	72.5052
2	1985-01-02 00:00:00	70.672
3	1985-01-03 00:00:00	62.4502
4	1985-01-04 00:00:00	57.4714
5	1985-01-05 00:00:00	55.3151
6	1985-01-06 00:00:00	58.0904
7	1985-01-07 00:00:00	62.6202
8	1985-01-08 00:00:00	63.2485
9	1985-01-09 00:00:00	60.5846
10	1985-01-10 00:00:00	56.3154

```
attach(mabase)
```

```
# Afficher les dernières lignes de mabase
```

```
tail(mabase)
```

```
# A tibble: 6 × 2
```

	DATE	PRODUCTION
	<dtm>	<chr>
1	2017-01-08 00:00:00	108.9312
2	2017-01-09 00:00:00	98.6154
3	2017-01-10 00:00:00	93.6137
4	2017-01-11 00:00:00	97.3359
5	2017-01-12 00:00:00	114.7212
6	2018-01-01 00:00:00	129.4048

```
# Vérifier si mabase est une série temporelle
```

```
is.ts(mabase)
```

```
[1] FALSE
```

```
# Obtenir un résumé statistique de mabase
```

```
summary(mabase)
```

```

DATE          PRODUCTION
Min. :1985-01-01 00:00:00.000 Length:397
1st Qu.:1993-01-04 00:00:00.000 Class :character
Median :2001-01-07 00:00:00.000 Mode :character
Mean :2001-01-21 18:19:02.569
3rd Qu.:2009-01-10 00:00:00.000
Max. :2018-01-01 00:00:00.000

```

Conversion en série temporelle

Conversion de la colonne de dates en format de Date et la colonne production en Numeric

```

mabase$DATE <- as.Date(mabase$DATE, format = "%m/%d/%Y")
mabase$PRODUCTION <- as.numeric(mabase$PRODUCTION)

```

Création de la série temporelle

```

mabase_st <- ts(mabase$PRODUCTION, start = c(min(year(mabase$DATE)),
                                             min(month(mabase$DATE))), frequency = 12)
# Affichons les 50 premiers valeurs de notre base
mabase_st_head <- head(mabase_st, 50)
mabase_st_head

```

```

      Jan  Feb  Mar  Apr  May  Jun  Jul  Aug  Sep
1985 72.5052 70.6720 62.4502 57.4714 55.3151 58.0904 62.6202 63.2485 60.5846
1986 73.3057 67.9869 62.2221 57.0329 55.8137 59.9005 65.7655 64.4816 61.0005
1987 73.8152 70.0620 65.6100 60.1586 58.8734 63.8918 68.8694 70.0669 64.1151
1988 79.8703 76.1622 70.2928 63.2384 61.4065 67.1097 72.9816 75.7655 67.5152
1989 77.9188 76.6822
      Oct  Nov  Dec
1985 56.3154 58.0005 68.7145
1986 57.5322 59.3417 68.1354
1987 60.3789 62.4643 70.5777
1988 63.2832 65.1078 73.8631
1989

```

courbe de la production d'électricité en fonction des années


```

# Conversion de la série temporelle en dataframe pour plotly
mabase_df <- data.frame(date = as.Date(time(mabase_st), origin = "1970-01-01"), production =
as.numeric(mabase_st))

# Création du graphique avec plotly
plot_ly(data = mabase_df,
        x = ~ date,
        y = ~ production,
        type = 'scatter',
        mode = 'lines') %>%
layout(title = "Production Électrique Mensuelle (1985-2018)",

```

```
yaxis = list(title = "Production électrique"),  
xaxis = list(title = "Année"))
```



La série temporelle montre une tendance globale à la hausse avec des variations saisonnières marquées. Il est possible de discerner des pics réguliers, ce qui suggère une forte saisonnalité.

Décomposons la série temporelle

La décomposition de la série La décomposition consiste à séparer une série temporelle en plusieurs composantes :

Tendance : La tendance représente la variation à long terme de la série. Elle peut être linéaire ou non linéaire.

Saisonnalité : La saisonnalité est la variation périodique due à des facteurs saisonniers (par exemple, les saisons, les jours de la semaine, etc.).

Composante résiduelle : C'est la partie de la série qui ne peut pas être expliquée par la tendance et la saisonnalité. Elle contient le bruit aléatoire.

La fonction `decompose` sépare la série en tendance, saisonnalité et résidus.

```
base_decom <- decompose(mabase_st)
```

La décomposition de la série temporelle de la production électrique de 1985 à 2018 présente les composantes suivantes :

Tendance

Afficher les 50 premières lignes de la tendance

```
trend_head <- head(base_decom$trend, 50)
trend_head
```

	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug
1985	NA	NA	NA	NA	NA	NA	62.19902	62.12050
1986	62.27651	62.45895	62.52765	62.59568	62.70227	62.73402	62.73112	62.83881
1987	64.18499	64.54704	64.90953	65.15792	65.40664	65.63851	65.99257	66.49904
1988	68.05069	68.45947	68.83859	69.10127	69.33243	69.57947	69.63505	69.57540
1989	70.35529	70.36895						
	Sep	Oct	Nov	Dec				
1985	61.99911	61.97134	61.97384	62.07004				
1986	63.06644	63.33784	63.59556	63.88935				
1987	66.94833	67.27178	67.50565	67.74527				
1988	69.72455	69.92993	70.10295	70.25483				
1989								

Tendance (trend) : La composante de tendance montre une augmentation progressive de la production électrique sur la période étudiée. Cette croissance pourrait être due à une augmentation de la demande énergétique, des améliorations technologiques, ou des politiques énergétiques favorables. La tendance semble se stabiliser vers la fin de la période, indiquant une possible saturation ou un équilibre atteint dans la production.

Saisonnalité

Afficher les 50 premières lignes de la saisonnalite

```
seasonal_head <- head(base_decom$seasonal, 50)
seasonal_head
```

	Jan	Feb	Mar	Apr	May	Jun
1985	13.2130393	5.7447473	-0.4936797	-9.4783551	-9.2221604	-1.1684236
1986	13.2130393	5.7447473	-0.4936797	-9.4783551	-9.2221604	-1.1684236
1987	13.2130393	5.7447473	-0.4936797	-9.4783551	-9.2221604	-1.1684236
1988	13.2130393	5.7447473	-0.4936797	-9.4783551	-9.2221604	-1.1684236
1989	13.2130393	5.7447473				
	Jul	Aug	Sep	Oct	Nov	Dec
1985	6.1430139	6.2744514	-2.4478281	-8.8533539	-6.0395359	6.3280847
1986	6.1430139	6.2744514	-2.4478281	-8.8533539	-6.0395359	6.3280847
1987	6.1430139	6.2744514	-2.4478281	-8.8533539	-6.0395359	6.3280847

```
1988 6.1430139 6.2744514 -2.4478281 -8.8533539 -6.0395359 6.3280847
1989
```

Saisonnalité (seasonal) : La composante saisonnière révèle des variations récurrentes et régulières chaque année. Les pics et creux saisonniers sont constants en amplitude et en fréquence, ce qui suggère que certains mois ou saisons de l'année sont systématiquement associés à des augmentations ou des diminutions de la production électrique.

Résidus

```
# Afficher les 50 premières lignes des residus
```

```
random_head <- head(base_decom$random, 50)
```

```
random_head
```

	Jan	Feb	Mar	Apr	May	Jun
1985	NA	NA	NA	NA	NA	NA
1986	-2.18385184	-0.21679311	0.18812551	3.91557173	2.33359373	-1.66509728
1987	-3.58282684	-0.22978478	1.19414634	4.47903423	2.68891873	-0.57828895
1988	-1.39343101	1.95797772	1.94789217	3.61548423	1.29623123	-1.30134311
1989	-5.64952684	0.56850689				


	Jul	Aug	Sep	Oct	Nov	Dec
1985	-5.72183472	-5.14644728	1.03331561	3.19741639	2.06619426	0.31637785
1986	-3.10863472	-4.63166395	0.38189061	3.04771639	1.78567342	-2.08203882
1987	-3.26618472	-2.70659311	-0.38540522	1.96047889	0.99819009	-3.49565548
1988	-2.79645972	-0.08435145	0.23848228	2.20662472	1.04439009	-2.71981382
1989						

Résidus (random) : La composante résiduelle représente les fluctuations qui ne peuvent être expliquées ni par la tendance ni par la saisonnalité. Ces résidus semblent assez aléatoires, avec quelques variations importantes, ce qui peut indiquer des événements imprévus ou des perturbations temporaires dans la production électrique (par exemple, des pannes, des interventions de maintenance imprévues, ou des variations soudaines de la demande).

Représentation des composantes de la serie

```
plot(base_decom)
```


Decomposition of additive time series



Ajustement de la tendance en utilisant un modèle linéaire simple et multiple

Ajustement d'un modèle linéaire simple

Nous allons ajuster un modèle linéaire simple où la production dépend uniquement du temps:

Créons un dataframe avec les dates en tant que variable explicative

```
base_temps <- data.frame( Time = as.numeric(time(mabase_st)), Production =  
as.numeric(mabase_st))
```

#Affichons les 10 premiers valeurs

```
base_temps_head <- head(base_temps, 10)
```

```
base_temps_head
```

	Time	Production
1	1985.000	72.5052
2	1985.083	70.6720
3	1985.167	62.4502
4	1985.250	57.4714
5	1985.333	55.3151
6	1985.417	58.0904
7	1985.500	62.6202
8	1985.583	63.2485
9	1985.667	60.5846
10	1985.750	56.3154

Ajustons maintenant le modèle linéaire simple

```
model_lineaire_simple <- lm(Production ~ Time, data = base_temps)
model_lineaire_simple
```

Call:

```
lm(formula = Production ~ Time, data = base_temps)
```

Coefficients:

(Intercept)	Time
-2595.398	1.341

Résumé du modèle

```
summary(model_lineaire_simple)
```

Call:

```
lm(formula = Production ~ Time, data = base_temps)
```

Residuals:

Min	1Q	Median	3Q	Max
-21.6168	-6.3153	-0.4795	5.5767	21.5226

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-2.595e+03	8.957e+01	-28.98	<2e-16 ***
Time	1.341e+00	4.475e-02	29.97	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.515 on 395 degrees of freedom

Multiple R-squared: 0.6946, Adjusted R-squared: 0.6938

F-statistic: 898.2 on 1 and 395 DF, p-value: < 2.2e-16


Le modèle de régression linéaire indique que la production varie avec le temps. On a:

Production = -2595.398 + 1.341 × Time. Les résidus montrent une distribution centrée autour de zéro, suggérant un bon ajustement du modèle aux données. Avec un R-carré de 0.6946, environ 69,46 % de la variabilité de la production est expliquée par le temps, ce qui rend le modèle statistiquement significatif ($p < 2.2e-16$).

Visualisons la tendance ajustée pour voir

```
plot(base_temps$Time, base_temps$Production, main = "Modèle Linéaire Simple")
# Superposons la ligne de modèle linéaire
abline(model_lineaire_simple, col = "green")
```

Modèle Linéaire Simple



Ajustement de la Tendance avec un Modèle Linéaire Multiple

Pour un modèle linéaire multiple, on peut ajouter des termes saisonniers pour mieux capter les variations saisonnières.

On va ajouter des termes saisonniers (par exemple, des indicateurs pour les mois)

Ajoutons des termes saisonniers (par exemple, des indicateurs pour les mois)

```
base_temps$Month <- factor(cycle(mabase_st))
```

```
# Ajustons le modèle linéaire multiple
```

```
model_lineaire_multiple <- lm(Production ~ Time + Month, data = base_temps)
```

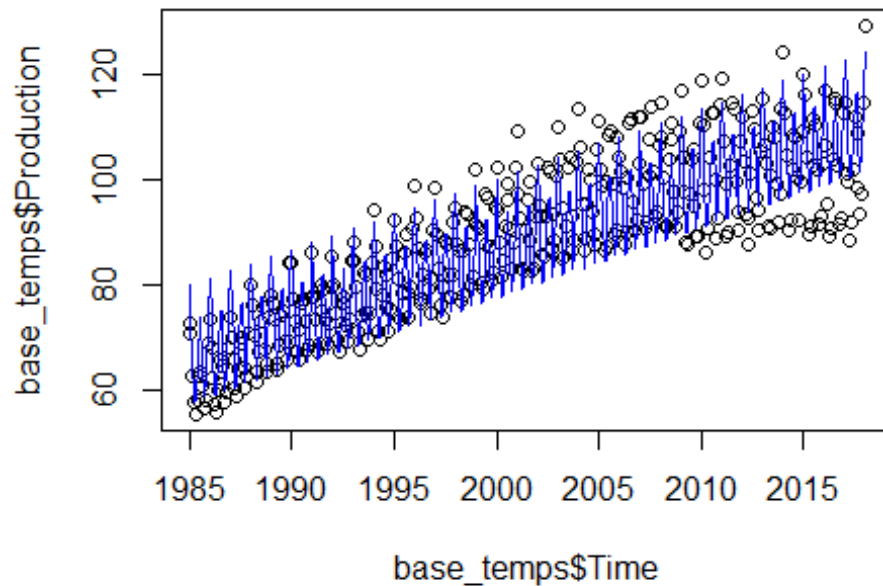
```
# Visualisation de la tendance ajustée
```

```
pred_values <- predict(model_lineaire_multiple, newdata=base_temps)
```

```
plot(base_temps$Time, base_temps$Production, main="Modèle Linéaire Multiple")
```

```
lines(base_temps$Time, pred_values, col="blue")
```

Modèle Linéaire Multiple



Comparaison des Modèles

Comparons les deux modèles en termes de performance, par exemple avec le R^2 ou l'AIC.

Les mesures R^2 et AIC fournissent des indications cruciales sur la performance et la pertinence des modèles linéaires dans l'analyse des données.

```
# Récupérons les valeurs d'ajustement
cds <- summary(model_lineaire_simple)$r.squared
cdm <- summary(model_lineaire_multiple)$r.squared
aic_simple <- AIC(model_lineaire_simple)
aic_multiple <- AIC(model_lineaire_multiple)
# Affichons les résultats
cat("R² du modèle linéaire simple: ", cds, "\n")

R² du modèle linéaire simple: 0.6945572

cat("R² du modèle linéaire multiple: ", cdm, "\n")

R² du modèle linéaire multiple: 0.9165092

cat("AIC du modèle linéaire simple: ", aic_simple, "\n")

AIC du modèle linéaire simple: 2831.257

cat("AIC du modèle linéaire multiple: ", aic_multiple, "\n")

AIC du modèle linéaire multiple: 2338.338
```

Un R^2 de 0.6945572 pour le modèle linéaire simple indique que près de 70% de la variance de la variable dépendante est expliquée par la variable indépendante utilisée. En revanche, le modèle linéaire multiple affiche un R^2 plus élevé à 0.9165092, suggérant qu'environ 92% de la variance est expliquée par toutes les variables indépendantes incluses. Le modèle linéaire multiple montre un score significativement plus bas à 2338.338 par rapport au modèle simple à 2831.257, indiquant ainsi une meilleure adéquation du modèle multiple à vos données observées.

2) Faisons une étude de la saisonnalité et analysons les résultats.

L'étude de la saisonnalité nous permet de comprendre les fluctuations récurrentes de notre série temporelle, tandis que l'analyse des résultats nous aide à interpréter les effets de la tendance et des variations saisonnières sur nos données. Utilisez ces informations pour prendre des décisions éclairées dans votre analyse de série temporelle.

Saisonnalité

```
# Afficher les 50 premières lignes de la saisonnalite
seasonal_head <- head(base_decom$seasonal,50)
seasonal_head
```

	Jan	Feb	Mar	Apr	May	Jun
1985	13.2130393	5.7447473	-0.4936797	-9.4783551	-9.2221604	-1.1684236
1986	13.2130393	5.7447473	-0.4936797	-9.4783551	-9.2221604	-1.1684236
1987	13.2130393	5.7447473	-0.4936797	-9.4783551	-9.2221604	-1.1684236
1988	13.2130393	5.7447473	-0.4936797	-9.4783551	-9.2221604	-1.1684236
1989	13.2130393	5.7447473				
	Jul	Aug	Sep	Oct	Nov	Dec
1985	6.1430139	6.2744514	-2.4478281	-8.8533539	-6.0395359	6.3280847
1986	6.1430139	6.2744514	-2.4478281	-8.8533539	-6.0395359	6.3280847
1987	6.1430139	6.2744514	-2.4478281	-8.8533539	-6.0395359	6.3280847
1988	6.1430139	6.2744514	-2.4478281	-8.8533539	-6.0395359	6.3280847
1989						

Les données de la composante saisonnière révèlent des variations distinctes mois par mois de la production électrique sur une période étendue de 1985 à 2018. Les résultats montrent les effets saisonniers constants sur une série temporelle étalée sur plusieurs années. Chaque mois, de janvier à décembre, présente des valeurs constantes au fil des années incluses dans nos données. Ces constantes indiquent l'impact moyen que chaque mois a sur la série temporelle par rapport à la tendance globale. Par exemple, janvier présente une valeur de 13.2130393, suggérant une augmentation constante chaque année à cette période.

Cette régularité dans les schémas saisonniers implique une prévisibilité relative dans la demande énergétique tout au long de l'année et Cette compréhension est cruciale pour la planification stratégique des capacités de production, l'optimisation des ressources et la réponse efficace aux fluctuations saisonnières de la demande, assurant ainsi une gestion stable et adaptative du réseau électrique.

En résumé, ces résultats fournissent une base solide pour comprendre et gérer les variations saisonnières dans nos données, améliorant ainsi la précision des prévisions et la capacité à réagir efficacement aux changements saisonniers.

3) Modéliser la série par la méthodologie de Box & Jenkins. Analyser et interpréter les sorties du logiciel R.

Modelisation Box & Jenkins

Pour modéliser la série temporelle par la méthodologie de Box & Jenkins, nous allons suivre les étapes suivantes dans R :

Tests de stationnarité

TEST AUGMENTE DE DICKEY-FULLER

Le test augmente de Dickey-FULLER (ADF) est utilisé pour vérifier la présence d'une racine unitaire dans une série temporelle, ce qui indique si la série est stationnaire ou non.

```
# H0: non stationnarité
```

```
adf.test(mabase_st)
```

Warning in adf.test(mabase_st): p-value smaller than printed p-value

Augmented Dickey-Fuller Test

data: mabase_st

Dickey-Fuller = -5.139, Lag order = 7, p-value = 0.01

alternative hypothesis: stationary

La p-value obtenue (0.01) est inférieure au seuil de signification typique de 0.05, ce qui signifie que nous rejetons l'hypothèse nulle selon laquelle la série a une racine unitaire. Par conséquent, l'hypothèse alternative selon laquelle la série est stationnaire est acceptée.

En d'autres termes, les résultats de ce test indiquent que notre série temporelle est stationnaire.

TEST PP

Le test de Phillips-Perron (PP) est également utilisé pour vérifier la présence d'une racine unitaire dans une série temporelle, similaire au test ADF.

```
# H0: non stationnarité
```

```
pp.test(mabase_st)
```

Warning in pp.test(mabase_st): p-value smaller than printed p-value

Phillips-Perron Unit Root Test

```
data: mabase_st
Dickey-Fuller Z(alpha) = -88.143, Truncation lag parameter = 5, p-value
= 0.01
alternative hypothesis: stationary
```

La p-value (0.01) est encore une fois inférieure au seuil de signification typique de 0.05, ce qui nous permet de rejeter l'hypothèse nulle de présence d'une racine unitaire. Par conséquent, nous acceptons l'hypothèse alternative selon laquelle la série est stationnaire. Les résultats de ce test confirment les conclusions du test ADF, indiquant que la série temporelle est stationnaire.

TEST KPSS

Le test KPSS (Kwiatkowski-Phillips-Schmidt-Shin) est utilisé pour tester l'hypothèse nulle selon laquelle une série temporelle est stationnaire autour d'une moyenne ou d'une tendance, contre l'hypothèse alternative selon laquelle elle est non stationnaire.

```
# H0: Stationnarite
kpss.test(mabase_st)
```

Warning in kpss.test(mabase_st): p-value smaller than printed p-value

KPSS Test for Level Stationarity

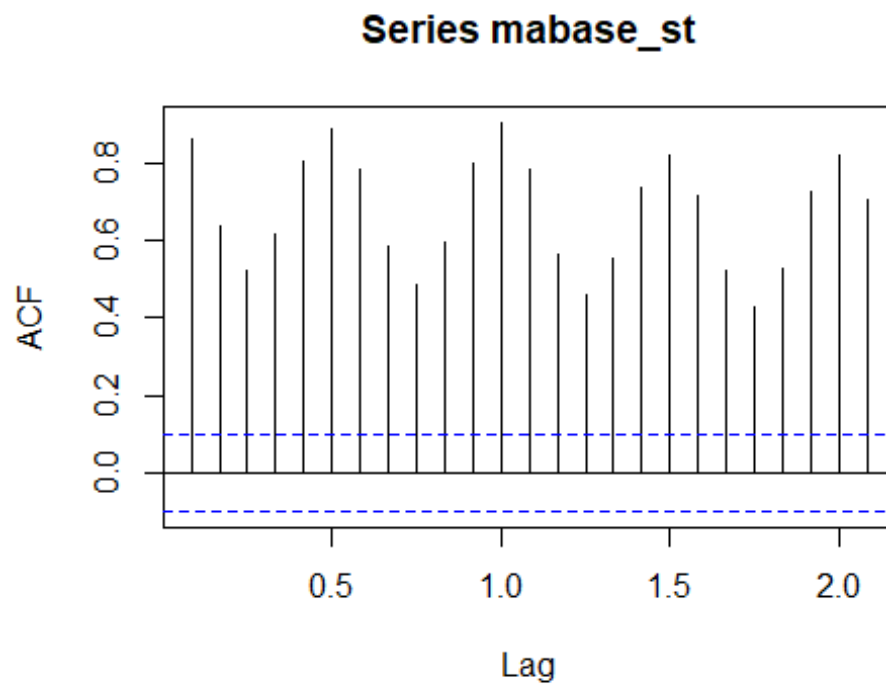
```
data: mabase_st
KPSS Level = 6.3058, Truncation lag parameter = 5, p-value = 0.01
```

La p-value (0.01) est inférieure au seuil de signification typique de 0.05, ce qui signifie que nous rejetons l'hypothèse nulle selon laquelle la série est stationnaire. Contrairement aux tests ADF et PP, le test KPSS suggère que notre série temporelle n'est pas stationnaire.


Identification du model

1. Pour identifier le modèle ARIMA approprié, nous devons analyser les autocorrélations (ACF) et les autocorrélations partielles (PACF) de la série.

```
# Tracé de l'ACF et de la PACF
acf(mabase_st)
```



```
pacf(mabase_st)
```




```
#Ensuite, nous utilisons auto.arima pour trouver les meilleurs paramètres (p, d, q) automatiquement.
```

```
model <- auto.arima(mabase_st)
summary(model)
```

```
Series: mabase_st
ARIMA(2,1,1)(0,1,1)[12]
```

```
Coefficients:
```

```
      ar1    ar2    ma1    sma1
      0.5503 -0.0683 -0.9477 -0.7635
s.e. 0.0544  0.0549  0.0193  0.0331
```

```
sigma^2 = 5.838: log likelihood = -888.05
AIC=1786.11 AICc=1786.27 BIC=1805.86
```

```
Training set error measures:
```

```
      ME    RMSE    MAE    MPE    MAPE    MASE
Training set -0.1474299 2.363849 1.791855 -0.2115265 1.942956 0.6278541
```

```
      ACF1
Training set -0.002715831
```

```
# Imprimer les détails du modèle
print(model)
```

```
Series: mabase_st
ARIMA(2,1,1)(0,1,1)[12]
```

```
Coefficients:
```

```
      ar1    ar2    ma1    sma1
      0.5503 -0.0683 -0.9477 -0.7635
s.e. 0.0544  0.0549  0.0193  0.0331
```

```
sigma^2 = 5.838: log likelihood = -888.05
AIC=1786.11 AICc=1786.27 BIC=1805.86
```


Le modèle ARIMA(2,1,1)(0,1,1)[12] est utilisé pour modéliser les données mensuelles. Les coefficients indiquent une influence significative des observations précédentes (ar1 = 0,5503) et une correction des erreurs de prévision passées (ma1 = -0,9477). Le terme saisonnier sma1 montre une correction saisonnière précédente. L'ajustement du modèle est raisonnable avec un σ^2 de 5,838 et une log-vraisemblance de -888,05.

Les valeurs AIC, AICc, et BIC sont respectivement de 1786,11, 1786,27, et 1805,86, indiquant un ajustement acceptable du modèle mais laissant place à des améliorations potentielles.

Diagnostic


Nous devons vérifier que les résidus du modèle sont un bruit blanc. Cela signifie que les résidus doivent être non corrélés et suivre une distribution normale.

```
# Résidus du modèle  
residus <- residuals(model)  
  
# Tracé des résidus  
plot(residus)
```



```
# Tracé de l'ACF des résidus  
acf(residus)
```

Series residus



```
# Test de Ljung-Box pour l'indépendance des résidus  
Box.test(residus, lag=20, type="Ljung-Box")
```

Box-Ljung test

```
data: residus  
X-squared = 25.662, df = 20, p-value = 0.1773
```

```
# Test de normalité des résidus  
shapiro.test(residus)
```

Shapiro-Wilk normality test

```
data: residus  
W = 0.98648, p-value = 0.0009324
```

Le test de Box-Ljung indique une statistique X^2 de 25.662 avec 20 degrés de liberté et une valeur de p de 0.1773, suggérant qu'il n'y a pas suffisamment de preuves pour rejeter l'hypothèse nulle d'absence d'autocorrélation dans les résidus. Cela suggère que le modèle capture efficacement la structure temporelle des données.

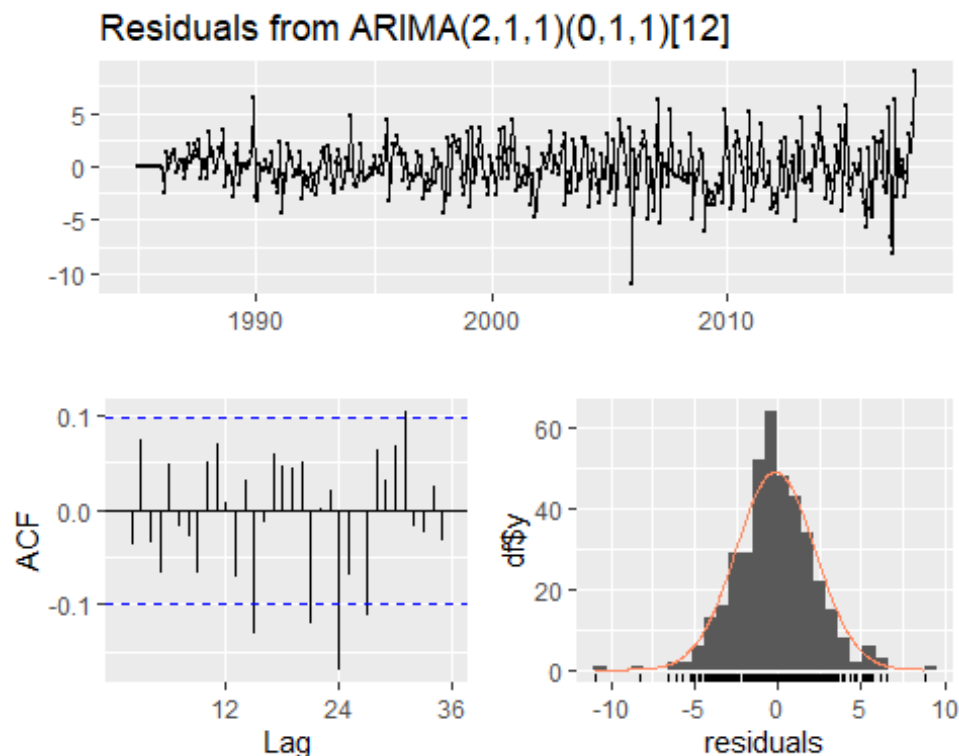
Cependant, le test de normalité de Shapiro-Wilk montre un W de 0.98648 avec un p-value très faible de 0.0009324, indiquant que les résidus ne suivent pas une distribution normale. Cela

pourrait suggérer que le modèle pourrait être amélioré pour mieux capturer la variabilité non expliquée par le modèle actuel.

Diagnostic des Résidus

Il est important de vérifier que les résidus du modèle sont proches d'un bruit blanc. Voici comment effectuer cette vérification.

```
# Plot des résidus  
checkresiduals(model)
```



Ljung-Box test

```
data: Residuals from ARIMA(2,1,1)(0,1,1)[12]  
Q* = 43.986, df = 20, p-value = 0.001511
```

Model df: 4. Total lags used: 24

```
# Test de Ljung-Box  
Box.test(residuals(model), lag = 24, type = "Ljung-Box")
```

Box-Ljung test

```
data: residuals(model)
```

```
X-squared = 43.986, df = 24, p-value = 0.007658
```

- On a Q^* est de 43.986 avec 20 degrés de liberté et un p-value de 0.001511. Ceci indique une forte autocorrélation significative dans les résidus jusqu'au lag 20.
- On a X-squared est de 43.986 avec 24 degrés de liberté et un p-value de 0.007658. Ce résultat confirme également une autocorrélation significative dans les résidus.

Le modèle ARIMA a un bon ajustement global, ces tests indiquent que les résidus présentent encore une autocorrélation non négligeable, suggérant des possibilités d'amélioration du modèle pour mieux expliquer la variabilité résiduelle des données.

4) Effectuer une prévision par ARIMA de la production électrique pour une période d'une année et une période de 3 années. Représenter graphiquement ces prévisions dans deux graphes différents avec leurs intervalles de confiance. Commenter.

prevision pour 1 an par arima

```
prev=predict(model,n.ahead=12)
```

```
prev
```

```
$pred
```

	Jan	Feb	Mar	Apr	May	Jun	Jul
2018		114.31111	104.45857	92.09910	93.63140	104.31821	113.65996
2019	122.04284						
	Aug	Sep	Oct	Nov	Dec		
2018	112.58325	101.93541	93.85642	97.12217	112.41629		
2019							

```
$se
```

	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug
2018		2.416146	2.821027	2.922366	2.956342	2.973647	2.986085	2.996905
2019	3.046708							
	Sep	Oct	Nov	Dec				
2018	3.007142	3.017149	3.027054	3.036902				
2019								


```
prev_arima2018=prev$pred
```

```
prev_arima2018
```

	Jan	Feb	Mar	Apr	May	Jun	Jul
2018		114.31111	104.45857	92.09910	93.63140	104.31821	113.65996
2019	122.04284						
	Aug	Sep	Oct	Nov	Dec		

```
2018 112.58325 101.93541 93.85642 97.12217 112.41629
2019
```

```
plot(mabase_st,xlim=c(1985,2019),ylim=range(c(mabase_st,prev_arima2018)),
     xlab='Mois',ylab='Production',main='Prevision de la production pour une annee',lwd=2)
lines(prev_arima2018,col="blue",lwd=3)
lines(prev_arima2018+2*prev$se,col="red",lty=3,lwd=2)
lines(prev_arima2018-2*prev$se,col="red",lty=3,lwd=2)
```




Graphe des previsions

```
mois=1:12
```

```
plot(mois,prev_arima2018, type='l', col='blue', lwd=3,
     cex.axis=0.6, xaxt='n', xlab='Mois',
     ylab='Production', main='Prevision de la production pour une annee par arima')
axis(1, 1:12, mois[1:12],tck=T,cex.axis=.6)
```

Prevision de la production pour une annee par arima



Graphique avec intervalles de confiance

prevision pour 3 ans par Arima


```
prev3an=predict(model,n.ahead=36)
prev_arima3ans=prev3an$pred
prev_arima3ans
```

	Jan	Feb	Mar	Apr	May	Jun	Jul
2018	114.31111	104.45857	92.09910	93.63140	104.31821	113.65996	
2019	122.04284	110.69451	103.24842	91.95762	93.91376	104.76087	114.16190
2020	122.57875	111.23047	103.78440	92.49360	94.44975	105.29685	114.69789
2021	123.11473						

	Aug	Sep	Oct	Nov	Dec
2018	112.58325	101.93541	93.85642	97.12217	112.41629
2019	113.10687	102.46692	94.39078	97.65757	112.95206
2020	113.64286	103.00290	94.92677	98.19356	113.48805
2021					

Prévisions basées sur un modèle ARIMA pour les années à venir (3 ans), couvrant janvier 2018 à décembre 2021.

```
plot(mabase_st,xlim=c(1985,2019),ylim=range(c(mabase_st,prev_arima3ans)),
     xlab='Mois',ylab='Production',main='Prevision de la production pour une periode de trois
annees',lwd=2)
lines(prev_arima3ans,col="blue",lwd=3)
lines(prev_arima3ans+2*prev3an$se,col="red",lty=3,lwd=2)
lines(prev_arima3ans-2*prev3an$se,col="red",lty=3,lwd=2)
```




Graphe des previsions

mois=1:36

```
plot(mois,prev_arima3ans, type='l', col='blue', lwd=3,
      cex.axis=0.6, xaxt='n', xlab='Mois',
      ylab='Production', main='Prevision de la production pour une periode de trois anneess')
```

```
axis(1, 1:36, mois[1:36],tck=T,cex.axis=.6)
```

Graphe avec intervalles de confiance

5) Effectuer une prévision pour une année et pour 3 années par lissage exponentiel et comparer graphiquement ces valeurs avec celles obtenues par la méthode ARIMA.

Lissage Exponentiel pour un an

```
lissage=HoltWinters(mabase_st)
prev_lis2018=predict(lissage,n.ahead=12)
prev_lis2018
```


	Jan	Feb	Mar	Apr	May	Jun	Jul
2018	115.12458	109.15159	97.69496	100.10703	111.28663	120.85122	
2019	128.16038						
	Aug	Sep	Oct	Nov	Dec		
2018	119.52513	108.92212	100.62997	103.68895	118.96908		
2019							

Ici on a les prévisions par lissage pour les mois de janvier 2018 et janvier à septembre 2019.

Représentation graphique

```
plot(lissage, xlim=c(1985,2019), xlab='Mois',
     ylab='Production électrique', main='Prevision électrique en 2018 par lissage',lwd=2)
lines(prev_lis2018,col=4,lwd=2)
```

Prevision electrique en 2018 par lissage



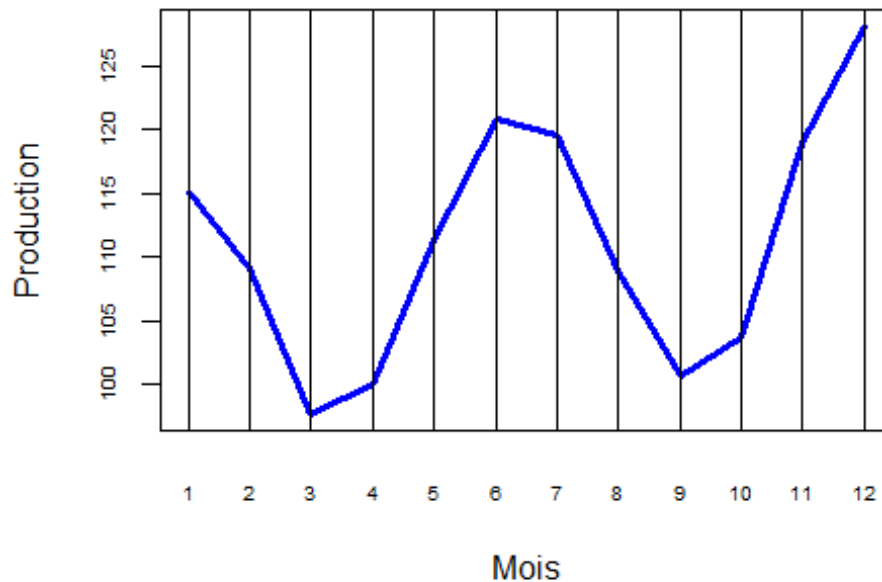
Grphe des previsions

mois=1:12

```
plot(mois,prev_lis2018, type='l', col='blue', lwd=3,  
      cex.axis=0.6, xaxt='n', xlab='Mois',  
      ylab='Production', main='Prevision de la production en 2018 par lissage')
```

```
axis(1, 1:12, mois[1:12],tck=T,cex.axis=.6)
```

Prevision de la production en 2018 par lissage




Graphe avec intervalles de confiance

```
lissage_ic=predict(lissage,n.ahead=12, prediction.interval=TRUE)
```

```
lissage_ic
```

	fit	upr	lwr
Feb 2018	115.12458	120.1664	110.08274
Mar 2018	109.15159	114.8146	103.48856
Apr 2018	97.69496	103.9175	91.47244
May 2018	100.10703	106.8427	93.37135
Jun 2018	111.28663	118.4991	104.07420
Jul 2018	120.85122	128.5108	113.19165
Aug 2018	119.52513	127.6071	111.44313
Sep 2018	108.92212	117.4055	100.43869
Oct 2018	100.62997	109.4967	91.76327
Nov 2018	103.68895	112.9230	94.45487
Dec 2018	118.96908	128.5565	109.38170
Jan 2019	128.16038	138.0885	118.23225

```
plot(lissage,lissage_ic, xlim=c(1985,2019),lwd=3,xlab='Mois',
     ylab='Production',main='Prevision de la production d electricite pour une annee par lissage')
```



On a ici les prévisions par lissage avec les intervalles de prédiction pour chaque mois à partir de février 2018 jusqu'à janvier 2019.

Lissage Exponentiel pour trois ans

```
lissage3ans=HoltWinters(mabase_st)
prev_lis3ans=predict(lissage,n.ahead=36)
prev_lis3ans
```


	Jan	Feb	Mar	Apr	May	Jun	Jul
2018		115.12458	109.15159	97.69496	100.10703	111.28663	120.85122
2019	128.16038	115.95284	109.97986	98.52323	100.93530	112.11490	121.67948
2020	128.98864	116.78111	110.80812	99.35149	101.76356	112.94316	122.50775
2021	129.81691						
	Aug	Sep	Oct	Nov	Dec		
2018	119.52513	108.92212	100.62997	103.68895	118.96908		
2019	120.35340	109.75038	101.45824	104.51721	119.79734		
2020	121.18166	110.57865	102.28650	105.34548	120.62561		
2021							

Représentation graphique

```
plot(lissage3ans, xlim=c(1985,2021), xlab='Mois',
     ylab='Production électrique', main='Prevision électrique en 2018 par lissage',lwd=2)
```

```
lines(prev_lis3ans,col=4,lwd=2)
```

Prevision electrique en 2018 par lissage



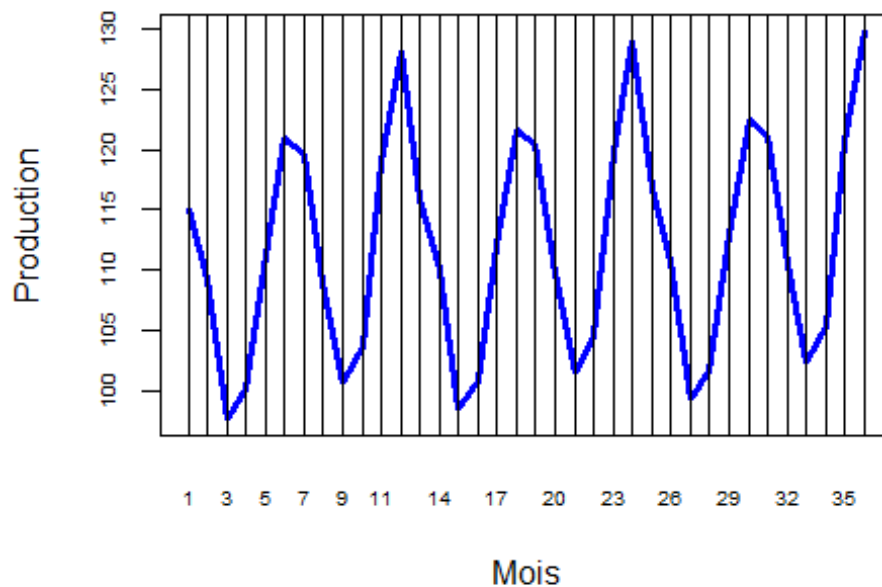
Graphe des previsions

```
mois=1:36
```

```
plot(mois,prev_lis3ans, type='l', col='blue', lwd=3,  
     cex.axis=0.6, xaxt='n', xlab='Mois',  
     ylab='Production', main='Prevision de la production en 3 ans par lissage')
```

```
axis(1, 1:36, mois[1:36],tck=T,cex.axis=.6)
```

Prevision de la production en 3 ans par lissage



Graphe avec intervalles de confiance


```
lissage3ans_ic=predict(lissage3ans,n.ahead=36, prediction.interval=TRUE)
lissage3ans_ic
```

	fit	upr	lwr
Feb 2018	115.12458	120.1664	110.08274
Mar 2018	109.15159	114.8146	103.48856
Apr 2018	97.69496	103.9175	91.47244
May 2018	100.10703	106.8427	93.37135
Jun 2018	111.28663	118.4991	104.07420
Jul 2018	120.85122	128.5108	113.19165
Aug 2018	119.52513	127.6071	111.44313
Sep 2018	108.92212	117.4055	100.43869
Oct 2018	100.62997	109.4967	91.76327
Nov 2018	103.68895	112.9230	94.45487
Dec 2018	118.96908	128.5565	109.38170
Jan 2019	128.16038	138.0885	118.23225
Feb 2019	115.95284	126.5816	105.32413
Mar 2019	109.97986	120.9169	99.04279
Apr 2019	98.52323	109.7602	87.28627
May 2019	100.93530	112.4643	89.40625
Jun 2019	112.11490	123.9288	100.30098
Jul 2019	121.67948	133.7716	109.58740
Aug 2019	120.35340	132.7174	107.98941
Sep 2019	109.75038	122.3804	97.12034

Oct 2019	101.45824	114.3488	88.56763
Nov 2019	104.51721	117.6632	91.37120
Dec 2019	119.79734	133.1939	106.40080
Jan 2020	128.98864	142.6311	115.34617
Feb 2020	116.78111	130.9416	102.62063
Mar 2020	110.80812	125.2015	96.41476
Apr 2020	99.35149	113.9740	84.72895
May 2020	101.76356	116.6117	86.91539
Jun 2020	112.94316	128.0136	97.87272
Jul 2020	122.50775	137.7972	107.21828
Aug 2020	121.18166	136.6871	105.67625
Sep 2020	110.57865	126.2970	94.86027
Oct 2020	102.28650	118.2150	86.35800
Nov 2020	105.34548	121.4814	89.20958
Dec 2020	120.62561	136.9663	104.28496
Jan 2021	129.81691	146.3598	113.27404

```
plot(lissage3ans,lissage3ans_ic, xlim=c(1985,2021),lwd=3,xlab='Mois',
     ylab='Production',main='Prevision de la production d electricite pour 3 ans par lissage')
```

Prevision de la production d electricite pour 3 ans par l



6) validation

Par apprentissage-test

Division de la base

```
# Nombre total de points de données
```

```
nombval <- length(mabase_st)
```

```
# Calculer l'index de division pour 85% des données
```

```
nombval_train <- floor(0.85 * nombval)
```

```
nombval_train
```

```
[1] 337
```

Diviser les données en base d'apprentissage

```
base_appr <- mabase_st[1:nombval_train]
```

```
# Affichons seulement les 50 premiers valeurs
```

```
base_appr_head <- head(base_appr, 50)
```

```
base_appr_head
```

```
[1] 72.5052 70.6720 62.4502 57.4714 55.3151 58.0904 62.6202 63.2485 60.5846  
[10] 56.3154 58.0005 68.7145 73.3057 67.9869 62.2221 57.0329 55.8137 59.9005  
[19] 65.7655 64.4816 61.0005 57.5322 59.3417 68.1354 73.8152 70.0620 65.6100  
[28] 60.1586 58.8734 63.8918 68.8694 70.0669 64.1151 60.3789 62.4643 70.5777  
[37] 79.8703 76.1622 70.2928 63.2384 61.4065 67.1097 72.9816 75.7655 67.5152  
[46] 63.2832 65.1078 73.8631 77.9188 76.6822
```

Diviser les données en base de test

```
base_test <- mabase_st[(nombval_train + 1):nombval]
```

```
# Affichons seulement les 50 premiers valeurs
```

```
base_test_head <- head(base_test, 50)
```

```
base_test_head
```

```
[1] 106.7340 102.9948 91.0092 90.9634 100.6957 110.1480 108.1756 99.2809  
[9] 91.7871 97.2853 113.4732 124.2549 112.8811 104.7631 90.2867 92.1340  
[17] 101.8780 108.5497 108.1940 100.4172 92.3837 99.7033 109.3477 120.2696  
[25] 116.3788 104.4706 89.7461 91.0930 102.6495 111.6354 110.5925 101.9204  
[33] 91.5959 93.0628 103.2203 117.0837 106.6688 95.3548 89.3254 90.7369  
[41] 104.0375 114.5397 115.5159 102.7637 91.4867 92.8900 112.7694 114.8505  
[49] 99.4901 101.0396
```

Ajuster le Modèle ARIMA sur la Base d'Apprentissage

```
# Ajuster le modèle ARIMA sur les données d'apprentissage
```

```
base_appr_arima <- auto.arima(base_appr)
```

```
summary(base_appr_arima)
```

Series: base_appr

ARIMA(2,1,2) with drift

Coefficients:

```
      ar1   ar2   ma1   ma2   drift
      0.9692 -0.8626 -1.0465 0.1415 0.1221
s.e. 0.0313 0.0289 0.0523 0.0498 0.0219
```

```
sigma^2 = 13.67: log likelihood = -915.77
AIC=1843.55 AICc=1843.8 BIC=1866.45
```

Training set error measures:

```
      ME   RMSE   MAE   MPE   MAPE   MASE
Training set -0.04635035 3.664873 2.822719 -0.1751415 3.268739 0.4494264
      ACF1
Training set -0.02580367
```

Le modèle ARIMA(2,1,2) avec drift ajuste la série avec deux termes auto-régressifs, deux termes de moyenne mobile, et une dérive. Les coefficients AR1 et AR2 sont significatifs, montrant une forte corrélation avec les valeurs précédentes, tandis que MA1 et MA2 capturent la relation avec les erreurs passées. La dérive de 0.1221 indique une légère tendance positive. La variance résiduelle est de 13.67, et le log-likelihood est de -915.77. Les critères d'information AIC, AICc, et BIC sont 1843.55, 1843.8, et 1866.45 respectivement. Les mesures d'erreur sur le jeu d'apprentissage montrent un RMSE de 3.6649 et un MAPE de 3.2687%, indiquant une erreur de prévision acceptable. L'ACF1 des résidus est faible (-0.0258), suggérant que le modèle capture bien la structure des données.

Effectuons des Prévisions sur la Période de Test pour une année

```
model_appr=arima(base_appr, order=c(2,1,2), seasonal=c(0,1,1))
model_appr
```

Call:

```
arima(x = base_appr, order = c(2, 1, 2), seasonal = c(0, 1, 1))
```

Coefficients:

```
      ar1   ar2   ma1   ma2   sma1
      0.9687 -0.8586 -1.0973 0.1339 -0.9574
s.e. 0.0319 0.0290 0.0683 0.0519 0.0445
```

```
sigma^2 estimated as 13.44: log likelihood = -916.89, aic = 1843.78
```

```
preval=predict(model_appr, n.ahead=12)
new_preval=preval$pred
new_preval
```

Time Series:

Start = 338

End = 349

Frequency = 1

```
[1] 111.53957 99.51290 91.28890 93.67337 103.06969 110.15033 108.96746
```

```
[8] 101.76766 95.83398 96.29288 101.85740 106.87933
```

```
summary(new_preval)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
91.29	96.18	101.81	101.74	107.40	111.54

```
summary(base_test)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
88.35	93.02	102.40	103.00	110.26	129.40

Le modèle s'ajuste bien aux données, avec des coefficients significatifs et des erreurs standard acceptables. La prévision montre une certaine variabilité dans la production électrique prévue pour les 12 prochains mois, ce qui est conforme aux données historiques. Le modèle peut être utilisé pour la planification future, mais il est important de continuer à surveiller les performances avec de nouvelles données

Graphique des previsions pour une annnee

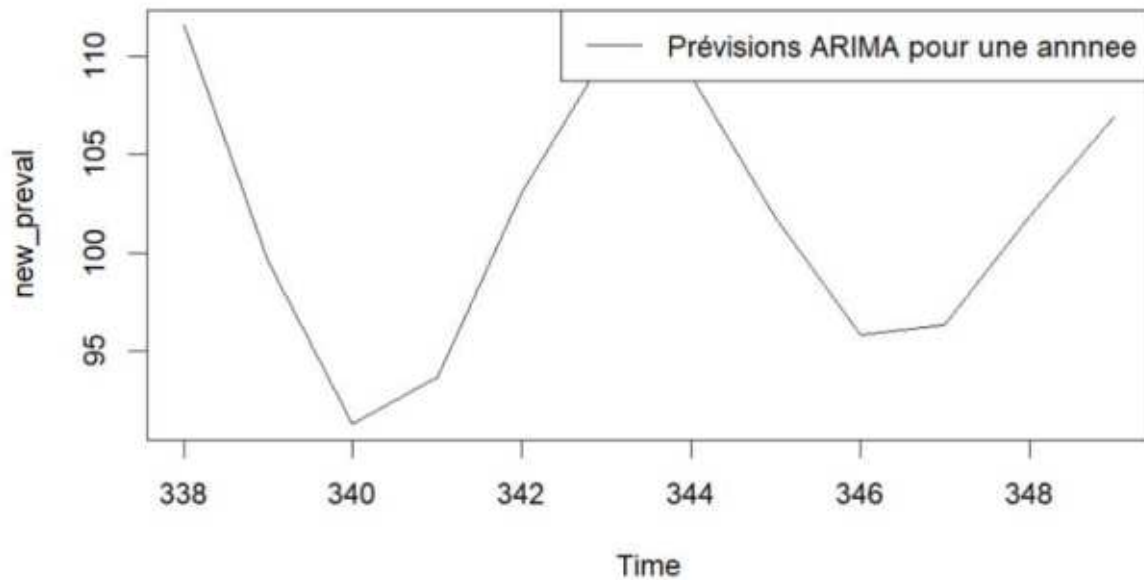
```
# Visualiser les prévisions
```

```
plot(new_preval, main="Prévisions ARIMA pour une annnee sur la Période de Test")
```

```
lines(base_test, lty=2)
```

```
legend("topright", legend=c("Prévisions ARIMA pour une annnee"), lty=c(1, 2))
```

Prévisions ARIMA pour une année sur la Période de Test



Effectuer des Prévisions sur la Période de Test pour une période de trois ans

```
model_appr=arima(base_appr, order=c(2,1,2), seasonal=c(0,1,1))
model_appr
```

Call:

```
arima(x = base_appr, order = c(2, 1, 2), seasonal = c(0, 1, 1))
```

Coefficients:

```
      ar1   ar2   ma1   ma2   sma1
      0.9687 -0.8586 -1.0973 0.1339 -0.9574
s.e. 0.0319 0.0290 0.0683 0.0519 0.0445
```

sigma^2 estimated as 13.44: log likelihood = -916.89, aic = 1843.78

```
preval3ans=predict(model_appr, n.ahead=36)
new_preval3ans=preval3ans$pred
new_preval3ans
```

Time Series:

Start = 338

End = 373

Frequency = 1

```
[1] 111.53957 99.51290 91.28890 93.67337 103.06969 110.15033 108.96746
[8] 101.76766 95.83398 96.29288 101.85740 106.87933 106.99204 102.81487
[15] 98.69697 98.31967 101.51515 104.96006 105.57907 103.24640 100.48059
```

```
[22] 99.82947 101.59880 103.89725 104.63012 103.39208 101.58892 100.93051
[29] 101.86627 103.36347 104.03584 103.42712 102.28555 101.72773 102.19289
[36] 103.14784
```

```
summary(new_preval3ans)
```

```
Min. 1st Qu. Median Mean 3rd Qu. Max.
91.29 100.82 102.24 102.26 103.93 111.54
```

```
length(new_preval3ans)
```

```
[1] 36
```

```
summary(base_test)
```

```
Min. 1st Qu. Median Mean 3rd Qu. Max.
88.35 93.02 102.40 103.00 110.26 129.40
```

Le modèle s'ajuste bien aux données, avec des coefficients significatifs et des erreurs standard acceptables. La prévision montre une certaine variabilité dans la production électrique prévue pour les 36 prochains mois, ce qui est conforme aux données historiques. Le modèle peut être utilisé pour la planification future, mais il est important de continuer à surveiller les performances avec de nouvelles données.

Graphique des prévisions pour une dure de trois année

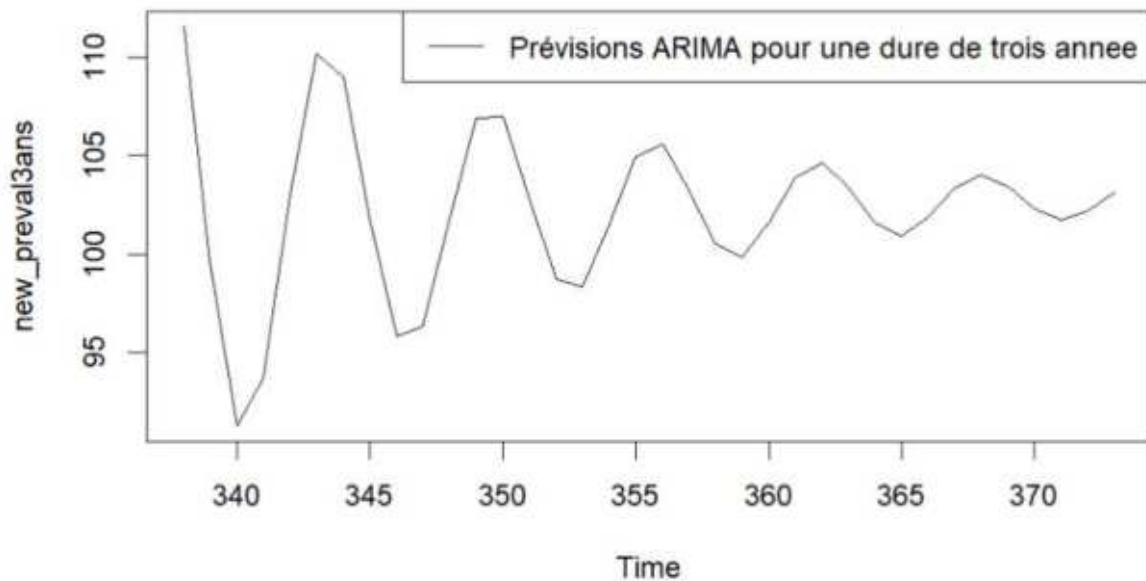
```
# Visualiser les prévisions
```

```
plot(new_preval3ans, main="Prévisions ARIMA sur la Période de Test pour 3 ans")
```

```
lines(base_test, lty=2)
```

```
legend("topright", legend=c("Prévisions ARIMA pour une dure de trois année"), lty=c(1, 2))
```

Prévisions ARIMA sur la Période de Test pour 3 ans



Nous avons fait aussi une validation par lissage pour en fin comparer les deux méthodes de validation.

Lissage exponentiel

Prévision par lissage exponentiel

```
# Définir la fréquence de la série temporelle
base_appr_ts <- ts(base_appr, frequency = 12)
# Appliquer le modèle Holt-Winters
lissage_appr <- HoltWinters(base_appr_ts)
# Afficher les résultats
print(lissage_appr)
```

Holt-Winters exponential smoothing with trend and additive seasonal component.

Call:

```
HoltWinters(x = base_appr_ts)
```

Smoothing parameters:

alpha: 0.4641251

beta : 0

gamma: 0.4965931

Coefficients:


```
[,1]  
a 99.97092336  
b 0.06902204  
s1 5.59939904  
s2 -2.81231065  
s3 -10.95259277  
s4 -8.22357864  
s5 2.16471610  
s6 11.54760703  
s7 9.75536520  
s8 -2.93185158  
s9 -10.43265334  
s10 -7.30950055  
s11 7.55714043  
s12 15.03143982
```

Les résultats du modèle de lissage exponentiel de Holt-Winters indiquent une prévision basée sur la tendance et la saisonnalité additive des données chronologiques. Les paramètres de lissage montrent un alpha de 0.464, suggérant que les observations récentes ont un poids significatif dans les prévisions futures. Le beta de 0 indique l'absence de variation de tendance à long terme dans ce modèle. Le gamma de 0.497 indique une variation saisonnière marquée. Les coefficients s1 à s12 représentent les effets saisonniers spécifiques pour chaque mois de l'année. Ensemble, ces résultats permettent de prévoir la série chronologique avec une prise en compte adaptée de la saisonnalité et des tendances récentes, tout en identifiant les variations périodiques significatives dans les données.

Representation Graphique

```
plot(lissage_appr)
```

Holt-Winters filtering



Prévision pour une année (12 mois)

```
prevision_1_an_lis <- predict(lissage_appr, n.ahead = 12, prediction.interval = TRUE)
prevision_1_an_lis
```

	fit	upr	lwr
Feb 29	105.63934	110.28625	100.99244
Mar 29	97.29666	102.41967	92.17364
Apr 29	89.22540	94.78389	83.66691
May 29	92.02343	97.98568	86.06119
Jun 29	102.48075	108.82109	96.14041
Jul 29	111.93266	118.62978	105.23554
Aug 29	110.20944	117.24528	103.17361
Sep 29	97.59125	104.95023	90.23227
Oct 29	90.15947	97.82798	82.49096
Nov 29	93.35164	101.31767	85.38561
Dec 29	108.28731	116.54014	100.03448
Jan 30	115.83063	124.36062	107.30064

Prévisions sur la production électrique par lissage appliqué sur une période d'un an, avec des intervalles de prédiction également fournis.

Prévision pour trois années (36 mois)

```
prevision_3_ans_lis <- predict(lissage_appr, n.ahead = 36, prediction.interval = TRUE)  
prevision_3_ans_lis
```


	fit	upr	lwr
Feb 29	105.63934	110.28625	100.99244
Mar 29	97.29666	102.41967	92.17364
Apr 29	89.22540	94.78389	83.66691
May 29	92.02343	97.98568	86.06119
Jun 29	102.48075	108.82109	96.14041
Jul 29	111.93266	118.62978	105.23554
Aug 29	110.20944	117.24528	103.17361
Sep 29	97.59125	104.95023	90.23227
Oct 29	90.15947	97.82798	82.49096
Nov 29	93.35164	101.31767	85.38561
Dec 29	108.28731	116.54014	100.03448
Jan 30	115.83063	124.36062	107.30064
Feb 30	106.46761	115.64778	97.28744
Mar 30	98.12492	107.55503	88.69481
Apr 30	90.05366	99.72726	80.38006
May 30	92.85170	102.76281	82.94059
Jun 30	103.30901	113.45207	93.16595
Jul 30	112.76093	123.13075	102.39110
Aug 30	111.03771	121.62944	100.44598
Sep 30	98.41951	109.22860	87.61043
Oct 30	90.98773	102.00989	79.96558
Nov 30	94.17991	105.41109	82.94873
Dec 30	109.11557	120.55196	97.67918
Jan 31	116.65889	128.29687	105.02092
Feb 31	107.29587	119.41847	95.17328
Mar 31	98.95319	111.26614	86.64023
Apr 31	90.88193	103.38234	78.38151
May 31	93.67996	106.36507	80.99486
Jun 31	104.13728	117.00443	91.27013
Jul 31	113.58919	126.63584	100.54254
Aug 31	111.86597	125.08968	98.64226
Sep 31	99.24778	112.64621	85.84934
Oct 31	91.81600	105.38691	78.24509
Nov 31	95.00817	108.74939	81.26695
Dec 31	109.94384	123.85328	96.03439
Jan 32	117.48716	131.56282	103.41149

Prévisions sur la production électrique par lissage appliqué sur une période de trois ans, avec des intervalles de prédiction également fournis.

Graphiques des prévisions

Graphique pour une année

```
indice_1_an <- 1:12  
plot(indice_1_an, prevision_1_an_lis[,1], type='l', col='blue', lwd=3, ylim=c(80, 130),  
      cex.axis=0.6, xaxt='n', xlab='Mois', ylab='Production', main='Prévision pour une année par  
Lissage')  
axis(1, 1:12, indice_1_an, tck=F, cex.axis=0.6)
```




Les observations montrent que le modèle par lissage exponentiel est efficace pour des séries avec des motifs saisonniers réguliers.

Graphique pour trois années

```
indice_3_ans <- 1:36  
plot(indice_3_ans, prevision_3_ans_lis[,1], type='l', col='blue', lwd=3, ylim=c(80, 130),  
      cex.axis=0.6, xaxt='n', xlab='Mois', ylab='Production', main='Prévision pour trois années par  
Lissage pour 3 ans')  
axis(1, 1:36, indice_3_ans, tck=F, cex.axis=0.6)
```

Prévision pour trois années par Lissage pour 3 ar




Ces observations suggèrent que le modèle Holt-Winters est efficace pour des séries avec des motifs saisonniers réguliers et sans tendances à long terme.

Graphique comparatif pour une année

```
plot(indice_1_an, prevision_1_an_lis[,1], type='l', col='blue', lwd=3, ylim=c(80, 130),  
     cex.axis=0.6, xaxt='n', xlab='Mois', ylab='Production', main='Prévision pour une année par  
ARIMA et Lissage')  
axis(1, 1:12, indice_1_an, tck=F, cex.axis=0.6)  
lines(indice_1_an, new_preval, col='red', lwd=3)  
legend("topright", legend=c("lissage pour une annee", "ARIMA pour une annee"), col=c("blue",  
"red"), lwd=3)
```

Prévision pour une année par ARIMA et Lissage



Ces deux modèles donnent des prévisions similaires, mais avec des différences notables dans le lissage et la réaction aux fluctuations. Le model arima montre une variabilité légèrement différente, avec des ajustements plus rapides aux changements.

Les prévisions ARIMA peuvent mieux s'ajuster aux fluctuations irrégulières et en bleu le model de lissage montre des prévisions plus lisses et plus régulières.